





1




2



3



4



9





10




11




12





17




18




19




20




21



22




23



24

Concept-clé : Données-> Information -> Connaissance -> Sagesse

27 octobre 2024



• Une **information** est une donnée à laquelle un sens et une interprétation ont été donnés.
 • Une information permet à un responsable opérationnel de prendre une décision (d'échelle locale ou à petite échelle) sur une action à mener.

Par exemple:
 • augmentation de 50 % du nombre d'incidents par rapport au mois précédent
 - (température=39°) : temps chaud
 - (âge=2 mois) : nourrisson


Fr. M. Chaouati

25

25

Concept-clé : Données-> Information -> Connaissance -> Sagesse.

27 octobre 2024



Connaissance : résultat d'une réflexion sur les informations analysées en se basant sur :
 • ses expériences, ses idées, ses valeurs, les avis d'autres personnes consultées pour l'occasion
 • sa propre expertise et celle de ses pairs permet aux responsables de confronter les informations au contexte de l'organisation et à d'autres contextes externes

Par exemple: Le responsable portant le rôle de gestionnaire des incidents peut établir une corrélation entre l'arrivée des nouveaux prestataires et l'augmentation des incidents.

- temps chaud et enfant nourrisson alors risque de déshydratation


Fr. M. Chaouati

26

26

Concept-clé : Données-> Information -> Connaissance -> Sagesse

27 octobre 2024



Sagesse : Consiste à utiliser judicieusement la connaissance pour prendre des décisions.

Exemple: les responsables de l'organisation prennent des décisions à long terme et des décisions stratégiques pour l'organisation informatique : réorganisation de la DSI, Formation, achat d'outil de gestion de service SI, mettre en place de nouvelle procédure de gestion de l'exploitation.

Fr. M. Chaouati

27

27

Bases de Données (BD) : c'est quoi ?

27 octobre 2024

- Est une collection de données persistantes utilisées par les systèmes d'application d'une entreprise.

Données persistantes : données acceptées par le SGBD qui ne peuvent être enlevées que par une requête explicite envoyée au SGBD.

Fr. M. Chaouati

28

28

Bases de Données (BD) : c'est quoi ? Exemples de BD

- Gestion des personnels, étudiants, cours, inscriptions, ... de l'université
- Système de réservation de places d'avion, de places de train
- Gestion des comptes clients
- Gestion des commandes
- Gestion d'une bibliothèque
- ...

29

Différents types de BD

- Il y en a pour tous les usages :
Bases de données personnelles : MS Access, ... : 100 Ko, 1 Mo
Bases de données professionnelles typiques : 1 Mo 100 Go
Bases de données professionnelles très grandes : Very Large Databases (VLDB) : > 40 To

30

Exemples de VLDB. (taille) :



31


Exemples de VLDB (taille) :



32

Les cas d'utilisation du Big Data

27 octobre 2024



33

Les cas d'utilisation du Big Data

27 octobre 2024



34

Les cas d'utilisation du Big Data

27 octobre 2024



35

Les cas d'utilisation du Big Data

27 octobre 2024



36

Les cas d'utilisation du Big Data

27 octobre 2024

Agriculture 2.0

- Les données brutes remontent désormais en très grand nombre (production, capteurs, météo), et la plus-value va être de les exploiter, de les croiser afin de prendre les décisions les plus pertinentes et les plus précises, à chaque moment.
- L'**agriculture de précision** est en cours de déploiement, avec le principe de « la bonne chose/dose, au bon moment, au bon endroit ». Projet Fertimap de l'OCP.



Pr. M. Ghazouani

37

37

Les cas d'utilisation du Big Data

27 octobre 2024

Le Big Data contre le Covid-19



Avec l'analyse informatique d'une quantité colossale de données médicales sur le Covid-19, les établissements de santé disposent d'un nouvel arsenal de lutte contre l'épidémie. L'objectif est de modéliser la dynamique de la contamination en anticipant les « points chauds » du virus avant qu'il ne se répande dans la population.

Pr. M. Ghazouani

38

38

Les cas d'utilisation du Big Data

27 octobre 2024

Le Big Data contre le Covid-19



oioyi.com
New smartphone app may accurately detect COVID-19 in peoples voices
London, Sep 5 (PTI) Scientists have developed a new smartphone app that may accurately detect COVID-19 infection in peoples voices by using ...

Pr. M. Ghazouani

39

39

Les cas d'utilisation du Big Data

27 octobre 2024



FACEBOOK : UN LOGICIEL D'IA A ÉLIMINÉ 65% DES DISCOURS HAINEUX

Avec une compréhension plus profonde et plus large du contenu, les logiciels d'intelligence artificielle contribuent grandement à éliminer les discours haineux. Environ 95% d'entre eux sont supprimés des plateformes numériques de Facebook.

Pr. M. Ghazouani

40

40

Les cas d'utilisation du Big Data

27 octobre 2024

Définir des profils client

"The world is changing very fast. Big will not beat small anymore. It will be the fast beating the slow". Rupert Murdoch

John is 27
Married
Two Children
Lives in New York
Orders pizza on Mondays
Reads non-fiction novels

Dans le domaine du commerce, des solutions Big Data permettront de relier les données non structurées émises par un client (comportement, intonations de la voix, ...) aux données classiques enregistrées à son sujet (historique des achats, service après-vente, ...) pour développer en temps réel une offre adaptée à ses besoins.

Pr. M. Ghaoui

41

Pourquoi Big Data ?

27 octobre 2024

- Difficulté de traiter la masse de données produites chaque jour et problème d'optimisation de base de données.
- Le traitement des données non structurées.
- La réplication des données.
- La recherche des données grâce au concept de données réparties et traitement distribué.
- Le stockage des données
- Le traitement des flux de données : Les informations sont traitées en temps réel.

Pr. M. Ghaoui

42

Le Big Data c'est quoi ?

27 octobre 2024

Littéralement, ce terme signifie **mégadonnées**, grosses données ou encore **données massives**. Il désigne des ensembles très volumineux de données qu'aucun outil classique de gestion de base de données ou de gestion de l'information ne peut vraiment manipuler.

Source : lebigdata.fr

Pr. M. Ghaoui

43

Le Big Data c'est quoi ?

27 octobre 2024

Sources de données :

- Les applications et services professionnels (ERP, CRM, etc.).
- Le Web (Sites d'actualité, d'e-commerce, gouvernementaux ou issus du monde associatif, etc.)
- Les médias sociaux
- Le mobile
- L'Internet des Objets (IOT)

En plus des données des systèmes opérationnels s'ajoutent désormais les données informelles, surtout issues du "crowdsourcing qui signifie création par la foule, tel Wikipédia".

Pr. M. Ghaoui

44

Le Big Data c'est quoi ?

Big Data

- Mégadonnées
- Données massives


Question :

- Big Data = Le volume de données ?

Fr. M. Ghazouani

27 octobre 2024

45



27 octobre 2024

46

Le Big Data c'est quoi ? La règle des 3V



Les organisations et les utilisateurs du monde entier créent plus de 2.5 EO de données par jour.

Fr. M. Ghazouani

27 octobre 2024

47



- Source de données :
- Applications et logiciels de gestion (ERP, CRM, etc...)
 - Le Web
 - Les médias sociaux
 - Le mobile
 - IOT

Le Big Data c'est quoi ? La règle des 3V

- Seulement 20% des données sont structurées
- 80% qui restent sont non-structurées : images, des vidéos, des textes, des voix



27 octobre 2024

48

48

Le Big Data c'est quoi ?

La règle des 3V

575 000 tweets
694 000 hours of video
171 million emails
60 seconds
5.7 million searches

Vélocité

27 octobre 2024

49

49

Le Big Data c'est quoi ?

Plus 2 V

575 000 tweets
694 000 hours of video
171 million emails
60 seconds
5.7 million searches

Véracité

Valeur

27 octobre 2024

50

50

Le Big Data c'est quoi ?

« le Big Data est une forte volumétrie, haute Vélocité et grande Variété de données qui exigent des techniques innovantes et rentables de traitement d'information pour une meilleure prise de décision ». L'institut Gartner.

27 octobre 2024

51

51

Principaux composants d'une architecture Big Data

Ingérer des données de diverses sources

Stocker le volume et la variété des données de manière rentable.

Fournir, gérer, surveiller et planifier des ressources.

Integration

Data storage

Data processing

security

operations

Répondre à une grande variété d'exigences de traitement

Autorisation d'authentification, Gestion des comptes utilisateurs, protection des données.

27 octobre 2024

52

52

L'écosystème du Big Data

Systèmes de fichiers

Hadoop HDFS
Hadoop HDFS (Hadoop Distributed File System) est un système de fichier distribué utilisé par : Yahoo!, Microsoft, LinkedIn, Facebook, ... qui vise à stocker d'importantes quantités de données dans un cluster d'ordinateurs et qui est responsable de la maintenance des données.

GlusterFS
Amazon, Red Hat

Ceph Filesystem
Inktank

27 octobre 2024

53

L'écosystème du Big Data

Bases NoSQL

Base NoSQL, c'est Not only SQL. Elles désignent une famille de systèmes de gestion de base de données (SGBD) qui s'écarte du paradigme classique des bases relationnelles. Elles sont apparues car les bases de données relationnelles ne répondent plus aux besoins d'analyse sur des données massives et surtout non structurées et réparties sur différents serveurs.

mongoDB

elasticsearch

APACHE HBASE

cassandra

neo4j

HYPERTABLE

27 octobre 2024

54

L'écosystème du Big Data

Bases NewSQL

Apache Hive
Apache Hive est un système d'entrepôt de données open source. Il permet d'interroger et d'analyser des ensembles de données volumineux (Big Data) stockés dans des fichiers Hadoop.

APACHE DRILL
Apache Drill est un framework logiciel open-source qui supporte les applications temps réel distribuées pour l'analyse interactive de jeux de données à grande échelle.

Impala
Contrairement à Hive, Impala n'utilise pas MapReduce. Il dispose en effet de son propre moteur de traitement qui doit être installé sur les nœuds de votre cluster Hadoop.

27 octobre 2024

55

L'écosystème du Big Data

Intégration de données

• Apache Flume est un logiciel de la fondation Apache destiné à la collecte et à l'analyse de fichiers de log. L'outil est conçu pour fonctionner au sein d'une architecture informatique distribuée et ainsi supporter les pics de charge.

FLUME

oozie

APACHE STORM

nifi

Flink

27 octobre 2024

56

L'écosystème du Big Data
Intégration de données

27 octobre 2024

- Apache Sqoop s'agit de composants logiciels qui structurent et transfèrent d'importantes quantités de données entre hadoop et les bases de données relationnelles.



Pr. M. Ghazouani

57

L'écosystème du Big Data
Intégration de données

27 octobre 2024

- Apache Storm est un Système pour le traitement en temps réel des données en flux.



Pr. M. Ghazouani

58

L'écosystème du Big Data
Intégration de données

27 octobre 2024

- Nifi est un logiciel libre de gestion de flux de données. Il permet de gérer et d'automatiser des flux de données entre plusieurs systèmes informatiques, à partir d'une interface web et dans un environnement distribué.



Pr. M. Ghazouani

59

L'écosystème du Big Data
Intégration de données

27 octobre 2024

- Apache Flink est un framework open source de traitement des données en flux.



Pr. M. Ghazouani

60

L'écosystème du Big Data

Programmation distribuée


hadoop
MapReduce


Pig


APACHE
Spark


APACHE
KUDU


Apache
Hama

Il vient compléter la couche de stockage pour permettre des analyses rapide

Un framework pour l'analyse big data

61

L'écosystème du Big Data

Machine Learning


Spark
MLlib
The Machine Learning Library


mahout


WEKA
The University of Waikato


H₂O


julia

62

L'écosystème du Big Data

Visualisation


IBM
COGNOS


QlikView


Spotfire


SAP
Business Objects


MicroStrategy


+tableau


Pentaho
reporting


kibana


ZOOMDATA


Power BI

63


L'écosystème du Big Data

Sécurité



Sentry


Apache
Ranger

64



65



66



67