




The Best Big Data Platforms

Pr. Ghazouani mohamed

1




2

13 février 2026

Introduction

Les distributions Hadoop sont des suites logicielles regroupant les composants de l'écosystème Hadoop de manière **préconfigurée**. Elles simplifient radicalement le cycle de vie d'un cluster : de l'installation initiale à la configuration, jusqu'à la coordination et l'administration centralisée des services.

Pr. M. Ghazouani



3

13 février 2026

Avantages

Voici les principaux avantages d'une distribution :

La gestion de "l'Enfer des Dépendances" :

C'est l'argument numéro un. L'écosystème Hadoop n'est pas un seul logiciel, mais une collection de dizaines de projets open source (HDFS, YARN, Spark, Hive, ZooKeeper, HBase, Kafka, Sqoop, PIG, NIFI, etc.).

- **Le problème Vanilla** : La version 3.2 de Spark peut ne pas fonctionner avec la version 2.1 de Hive, qui elle-même nécessite une version spécifique de Java et de ZooKeeper. Trouver la combinaison exacte qui ne plante pas est un travail titanesque.
- **L'avantage Distribution** : L'éditeur a déjà testé et validé l'intégration de tous les composants ensemble. Les éditeurs ont déjà testé des milliers de combinaisons pour vous dire : *"Voici le pack version 2026 : tout fonctionne ensemble, ne touchez à rien !"*



Pr. M. Ghazouani

4

13 février 2026

Avantages

- **Facilité de déploiement et de mise à jour**
- **Installation centralisée** : Au lieu de modifier manuellement des fichiers de configuration XML sur 50 ou 100 serveurs via des scripts SSH, les distributions offrent des installateurs graphiques (wizards).
- **Outils d'administration et de monitoring (GUI)**
Gérer un cluster en ligne de commande (CLI) est faisable mais complexe et risqué.
- **Interfaces visuelles** : Les distributions viennent avec des outils puissants comme **Ambari** qui permet de **gérer, surveiller et sécuriser** des clusters Hadoop (ou Cloudera Manager).
- **Visibilité** : Ces outils permettent de visualiser l'état de santé du cluster, de redémarrer des services, de voir les logs et de modifier la configuration de 100 nœuds en un seul clic.
- **Support Technique et SLA** : Vous avez accès à un support 24/7 avec des ingénieurs qui peuvent intervenir directement sur vos incidents et des mises à jours fiables.


Pr. M. Ghazouani

5

5

13 février 2026

Introduction




Pr. M. Ghazouani

6

6

13 février 2026

« What I hear, I forget. What I see, I remember. What I do, I understand »



Hortonworks Sandbox HDP est une **version de démonstration** (une mini-plateforme) de la distribution Hadoop de Hortonworks, appelée **HDP – Hortonworks Data Platform**.

HDP est :

- une **machine virtuelle (VM)**
- contenant une **version miniature d'un cluster Hadoop HDP**
- fournie par Hortonworks pour **l'apprentissage, le test et le développement**.

Pr. M. Ghazouani

7

7

13 février 2026

Fin de la partie

Pr. M. Ghazouani

8

8