

TP4

Cours : Bio-Informatique

NGS : Contrôle Qualité des Données (FastQC)

Objectif :

Les données de séquençage à haut débit (NGS) contiennent souvent des erreurs dues au séquenceur, aux adaptateurs ou à la qualité des bases.

Avant toute analyse (alignement, variant calling, RNA-seq), une étape de contrôle qualité est indispensable.

Dans ce TP, vous allez analyser des fichiers FASTQ à l'aide de FastQC, accessible en ligne via Galaxy.

Accès à la plateforme :

Galaxy : <https://usegalaxy.eu> (ou <https://usegalaxy.fr>)

Les données :

SRA ID : [SRR36432525](https://www.ncbi.nlm.nih.gov/sra/SRR36432525)

Partie 1 : Prise en main de Galaxy

- Créer un compte Galaxy
- Importer le fichier FASTQ fourni
- Vérifier le format du fichier

Partie 2 : Lancement de FastQC

- Rechercher FastQC dans la barre d'outils
- Lancer l'analyse sur le fichier FASTQ
- Ouvrir le rapport FastQC généré

Partie 3 : Analyse des résultats

Pour chaque module FastQC, répondre aux questions suivantes :

1. Qualité par base (Per base sequence quality)
 - La qualité est-elle homogène ?
 - Observe-t-on une chute de qualité en fin de lecture ?

- Le fichier est-il acceptable ?
- 2. Qualité par séquence (Per sequence quality scores)
 - Y a-t-il beaucoup de reads de mauvaise qualité ?
 - Quelle est la qualité moyenne globale ?
- 3. Contenu en GC (Per sequence GC content)
 - La distribution est-elle normale ?
 - Que peut indiquer une distribution anormale ?
- 4. Contenu en bases (Per base sequence content)
 - Les proportions A/T/G/C sont-elles équilibrées ?
 - À quoi peut être dû un déséquilibre ?

Partie 4 : Interprétation et décision

Le fichier FASTQ est-il :

- exploitable directement ?
- exploitable après nettoyage ?
- inutilisable ?