



Partie 1 — Variable Cible et Déséquilibre des Classes

Q 1.1 Distribution de la variable cible — Attrition_Flag



1. Ratio = **5,22** (16,1% de churn) → déséquilibre **modéré**
2. Accuracy trompeuse car 83,9% sans apprentissage → privilégier **F1-score, AUC-ROC, précision/rappel**
3. Va sur-prédire **Existing Customer** (classe majoritaire) car minimise l'erreur globale

Q 1.2 Ratio de churn par segment — première exploration croisée



4. **Card_Category** : écart = 25,0% (Platinum) - 14,8% (Silver) = **10,2 points** (plus grande variation)
5. **Corrélation** : Platinum (25%) > Gold (18,1%) > Blue (16,1%) > Silver (14,8%).
Hypothèse métier : Clients premium (Platinum/Gold) paient plus → attendent plus en retour → plus déçus si service insuffisant → churn plus élevé.
6. **Peu discriminante** : écart = 17,4% (F) - 14,6% (M) = **2,8 points seulement** → différence faible comparée aux autres variables.

Partie 2 — Analyse des Variables Catégorielles


Q 2.1 Distribution des 5 variables catégorielles

7. Modalités majoritaires


Variable	Modalité majoritaire	%
Gender	F	52,9%
Education_Level	Graduate	30,9%
Marital_Status	Married	46,3%
Income_Category	Less than \$40K	35,2%
Card_Category	Blue	93,2%

8. Tendance **non monotone** : Doctorate churn plus (21,1%) que Graduate (15,6%) → plus diplômés = plus exigeants.
9. Blue = 93% → **petits échantillons** pour Gold/Platinum → statistiques peu fiables.
Recommandation : **grouper les cartes premium**.

Q 2.2 Visualisation interactive Sunburst — exploration croisée



Exploration Hiérarchique : Attribution → Genre → Type de Carte



10. Femmes/Platinum ou Hommes/Platinum — les cartes Platinum ont le taux de churn le plus élevé (~25%), mais effectifs très faibles → prudence.

11. Clients revenu < 40K et Graduate sont généralement **sur-représentés** parmi les Attrited (combinaison de deux catégories fréquentes avec taux de churn modéré à élevé).

Partie 3 — Distributions des Variables Numériques

Q 3.1 Statistiques descriptives avancées — Asymétrie et Kurtosis

=== STATISTIQUES DESCRIPTIVES COMPLÈTES ===									
	mean	std	min	25%	50%	75%	max	skewness	kurtosis
Customer_Age	46.326	8.017	26.0	41.000	46.000	52.000	73.000	-0.034	-0.289
Credit_Limit	8631.954	9088.777	1438.3	2555.000	4549.000	11067.500	34516.000	1.667	1.809
Months_on_book	35.928	7.986	13.0	31.000	36.000	40.000	56.000	-0.107	0.400
Total_Relationship_Count	3.813	1.554	1.0	3.000	4.000	5.000	6.000	-0.162	-1.006
Months_Inactive_12_mon	2.341	1.011	0.0	2.000	2.000	3.000	6.000	0.633	1.099
Contacts_Count_12_mon	2.455	1.106	0.0	2.000	2.000	3.000	6.000	0.011	0.001
Total_Revolving_Bal	1162.814	814.987	0.0	359.000	1276.000	1784.000	2517.000	-0.149	-1.146
Avg_Open_To_Buy	7469.140	9090.685	3.0	1324.500	3474.000	9859.000	34516.000	1.662	1.799
Total_Amt_Chng_Q4_Q1	0.760	0.219	0.0	0.631	0.736	0.859	3.397	1.732	9.994
Total_Trans_Amt	4404.086	3397.129	510.0	2155.500	3899.000	4741.000	18484.000	2.041	3.894
Total_Trans_Ct	64.859	23.473	10.0	45.000	67.000	81.000	139.000	0.154	-0.367

```

=== CLASSEMENT PAR ASYMÉTRIE ===
                                skewness
Total_Trans_Amt                2.041
Total_Amt_Chng_Q4_Q1          1.732
Credit_Limit                   1.667
Avg_Open_To_Buy               1.662
Months_Inactive_12_mon        0.633
Total_Trans_Ct                 0.154
Contacts_Count_12_mon         0.011
Customer_Age                  -0.034
Months_on_book                -0.107
Total_Revolving_Bal           -0.149
Total_Relationship_Count      -0.162
dtype: float64

```

12. 3 variables avec la plus forte asymétrie :

Variable	Skewness	Transformation proposée
Total_Trans_Amt	2,041	Log(x+1) ou Box-Cox
Total_Amt_Chng_Q4_Q1	1,732	Log(x+1) ou RobustScaler
Credit_Limit	1,667	Log(x+1) ou RobustScaler

→ Toutes > 1 = asymétrie forte → queue de distribution à droite

13. Customer_Age est-elle asymétrique ?

Non : skewness = **-0,034** (presque 0)


Distribution proche de la **normale** (légèrement symétrique, très légère queue à gauche)

14. Ratio moyenne/médiane pour Credit_Limit :

Ratio = 8631,95 / 4549 = 1,90

Interprétation : Ratio > 1 signifie **distribution asymétrique à droite** (queue longue vers les hautes valeurs). La moyenne est tirée vers le haut par les valeurs extrêmes (clients avec très hautes limites de crédit). La médiane (4549) représente mieux le client "typique".

Q 3.2 Distributions comparées — KDE Existing vs Attrited



15. Total_Revolving_Bal : pic particulier pour Attrited ?

Oui — pic à 0 pour les clients Attrited (absent chez Existing).

Interprétation métier : Ces clients n'utilisent plus leur crédit renouvelable (solde à zéro). Signe de **désengagement financier** avant la résiliation.

16. Avg_Utilization_Ratio : particularité autour de 0 ?

Oui — bosse importante à 0 uniquement chez Attrited.

Signification : Taux d'utilisation = solde renouvelable / limite de crédit = 0 → clients qui n'utilisent **plus du tout** leur carte. **Désengagement total** = signal fort de churn imminent.

17. Classement par pouvoir discriminant (KDE) :


Rang	Variable	Séparation
1	Months_Inactive_12_mon	Excellente (décalage net)
2	Total_Trans_Ct	Très bonne
3	Total_Trans_Amt	Très bonne
4	Avg_Utilization_Ratio	Bonne (pic à 0 discriminant)
5	Credit_Limit	Moyenne
6	Total_Revolving_Bal	Faible (pic à 0 mais chevauchement)


18. Seuil d'inactivité associé au churn :

Seuil = 3-4 mois d'inactivité

Les clients Attrited ont leur pic de distribution autour de **3-4 mois** (vs 2 mois pour Existing). **≥ 3 mois** d'inactivité = signal d'alerte fort.

Q 3.3 Boxplots et Violin Plots — Outliers et variabilité





19. Violin plot de Credit_Limit : distribution similaire entre Existing et Attrited ?

Non, pas totalement similaire :

Aspect	Existing	Attrited
Forme	Queue longue à droite (asymétrique)	Queue moins étendue
Variabilité	Plus large (IQR et étendue)	Moins large
Médiane	~4600€	~4200€ (plus basse)

Interprétation : Les clients Attrited ont des limites de crédit **plus faibles** et **moins dispersées** → clients à crédit limité = plus de risque de churn.

20. Avg_Utilization_Ratio : que représente la bosse à 0 dans le violin des Attrited ?

Groupe cohérent (pas un outlier isolé).

- La **bosse épaisse** à 0 = nombreux clients Attrited avec **taux d'utilisation = 0**
- **Signification :** Ces clients n'utilisent **plus du tout** leur crédit (solde = 0)
- **C'est un signal métier fort** = désengagement total, phase terminale avant churn

Ce n'est pas un outlier technique mais un **segment comportemental** à forte valeur prédictive.

21. La tranche d'âge influence-t-elle le type de carte souscrit ?

Oui, tendance nette :

Carte	Tranche d'âge dominante	Interprétation
Blue	Toutes les tranches (uniforme)	Carte de base


Silver	44-53 ans	Approche de la retraite
Gold	35-44 ans	Plein carrière, revenus élevés
Platinum	54+ ans	Senior, patrimoine établi

Tendance par génération :

- **Jeunes (< 35 ans)** : Blue dominant
- **35-53 ans (actifs)** : Silver, Gold émergent
- **54+ ans (pré-retraite/retraite)** : Platinum présent

Partie 4 — Corrélations et Relations Bivariées

Q 4.1 Matrice de corrélation — Pearson et Spearman




22. Credit_Limit ↔ Avg_Open_To_Buy ($r=0,996$) — lien mathématique attendu.

23. Pearson (0,807) et Spearman ($\sim 0,85-0,90$) proches → relation linéaire et monotone.

24. Paires à traiter : Credit_Limit/Avg_Open_To_Buy (supprimer une), Customer_Age/Months_on_book (supprimer une). Solutions : suppression, régularisation L1/L2, PCA.

25. Non — Pearson ne capte pas les non-linéaires. Exemple : Customer_Age vs churn (relation en U) → Pearson ≈ 0 .


Q 4.2 Corrélations des features avec la variable cible



26. Top 3 : Total_Trans_Ct (-0,376), Total_Revolving_Bal (-0,241), Total_Trans_Amt (-0,224) → signe **négalif** cohérent avec KDE (les Attrited ont des faibles valeurs)
27. Customer_Age = **mauvais prédictieur** (corr = 0,018) → relation probablement **non-linéaire** (en U) non capturée par corrélation
28. **Pas toujours**, mais souvent oui → Spearman est **robuste aux outliers** et aux distributions **asymétriques** (cas des données financières)

Partie 5 — Visualisations Avancées et Synthèse Métier

Q 5.1 Scatter plot — Transactions vs Solde renouvelable



29. Oui — Attrited avec Total_Revolving_Bal = 0 mais transactions actives → désengagement du crédit revolving = étape **pré-churn**.

30. Seuil ≈ 60-70 transactions : au-dessus → très peu de churn ; en-dessous → zone à risque.

Q 5.2 Profil moyen — Comparaison Existing vs Attrited

	Existing (moy.)	Attrited (moy.)	Difference (%)
Customer_Age	46.26	46.66	0.9
Months_on_book	35.88	36.18	0.8
Total_Relationship_Count	3.91	3.28	-16.2
Months_Inactive_12_mon	2.27	2.69	18.5
Contacts_Count_12_mon	2.36	2.97	26.1
Credit_Limit	8726.88	8136.04	-6.8
Total_Revolving_Bal	1256.60	672.82	-46.5
Total_Trans_Amt	4654.66	3095.03	-33.5
Total_Trans_Ct	68.67	44.93	-34.6

	Existing	Attrited
Customer_Age	0.005	0.005
Months_on_book	0.004	0.004
Total_Relationship_Count	0.000	0.000
Months_Inactive_12_mon	0.000	0.000
Contacts_Count_12_mon	0.000	0.000
Credit_Limit	1.000	1.000
Total_Revolving_Bal	0.144	0.082
Total_Trans_Amt	0.533	0.380
Total_Trans_Ct	0.008	0.005

31. Total_Revolving_Bal : **-46,5%** → Règle : "Baisse du solde renouvelable > 40% = signal d'alerte"

32. Attrited = **légèrement plus anciens** (+0,8%) → Surprenant mais l'ancienneté n'est **pas discriminante** (corr ~ 0)

33. **3 actions :**

- Alerte** sur baisse du solde revolving → campagne rétention
- Récompenser** les clients avec ≥ 70 transactions/mois (seuil protecteur)
- Former les conseillers** : les Attrited contactent +26% le service client → détecter les signaux

Section Bonus — Pour aller plus loin

