



Partie 1 — SVM Linéaire : Visualisation de la Marge

Q 1.1 Visualisation de la marge maximale — données 2D linéairement séparables



1. **3 vecteurs support** (2 classe -1, 1 classe +1). Ils sont **exactement sur la marge** ($w \cdot x + b = \pm 1$).
2. L'hyperplan **ne changerait pas** — seuls les vecteurs support définissent la frontière. Les autres points sont inutiles.
3. $\|w\| = \sqrt{0.2005^2 + 0.1766^2} = 0.2672 \rightarrow \text{Marge} = 2/0.2672 = 7.4859$ ✅ Correspond exactement à la valeur affichée.


Q 1.2 Effet du paramètre C — Soft Margin



4. $C=0.01 \rightarrow$ marge **plus grande** (5,5) et **17 SV** ; $C=100 \rightarrow$ marge **plus petite** (3,19) et **3 SV**.
5. Avec $C=1000$, encore **2 violations** $\rightarrow$ données **non parfaitement séparables** (chevauchement).
6. **C modéré (1-10)** $\rightarrow$ compromis optimal biais/variance, robuste au bruit.
7. C du SVM **analogue** à C de la Logistique : les deux sont l'**inverse de la régularisation**. C grand = moins de régularisation (sur-apprentissage), C petit = plus de régularisation (sous-apprentissage).


Partie 2 — Le Kernel Trick : Séparation Non-Linéaire

Q 2.1 Comparaison linéaire vs RBF — données en lune



8. SVM linéaire accuracy $\approx 0,85 \rightarrow$ **échoue** à séparer les lunes (résultat attendu, donnée non-linéaire).
9. RBF $\rightarrow$ frontière **courbe**, gain $\approx +0,05$ à $+0,10$ (capture la forme non-linéaire).
10. RBF meilleur que polynomial degré 3 ($\approx 0,94$ vs $\approx 0,90$ - $0,92$). RBF plus **flexible** (frontières locales), polynomial trop **rigide** (forme globale imposée).


Q 2.2 Données en cercles concentriques — SVM RBF vs Linéaire



11. Accuracy linéaire $\approx 0,44$ (proche du hasard). Une droite ne peut pas séparer des cercles car la frontière naturelle est **radiale** (dépend du rayon $r^2 = x_1^2 + x_2^2$).

12. Transformation $\phi(x_1, x_2) = (x_1^2, \sqrt{2} \cdot x_1 \cdot x_2, x_2^2)$ rend les cercles **linéairement séparables** en 3D. C'est le **noyau polynomial de degré 2** ($K(x, z) = (x \cdot z)^2$) — le kernel trick calcule le produit scalaire en 3D sans jamais calculer $\phi(x)$.


Q 2.3 Effet de gamma sur le noyau RBF — biais/variance



13. gamma=0,01 → frontière **très lisse**, sous-apprentissage (train≈0,84, test≈0,85).
 14. gamma=100 → frontière **entoure chaque point**, train=1,00 mais test≈0,90 → **sur-apprentissage sévère**.
 15. gamma **optimal** ≈ 1 (train=test≈0,94). gamma='scale' ≈ 0,5 → proche de l'optimal, bon point de départ par défaut.


Partie 3 — Optimisation de C et Gamma par GridSearchCV

Q 3.1 GridSearchCV 2D — Heatmap C × gamma



16. Zone optimale : $C \geq 1$, $\gamma \approx 1$ (score max 0,9463). $\gamma < 0,1 \rightarrow$ underfitting.
17. Coin supérieur droit (C, grand gamma) $\rightarrow$ **overfitting** (mémorisation du bruit). Coin inférieur gauche (C, gammapetits) $\rightarrow$ **underfitting** (modèle trop simple).
18. Pipeline **essentiel** pour éviter le **data leakage** : le scaler est refitté sur chaque fold d'entraînement. Scaler avant GridSearch = contamination des données de validation par les statistiques du train complet $\rightarrow$ estimation **biaisée** des performances.

Q 3.2 Courbe de validation — C avec gamma fixé



19. Courbe en **U inversé** : $C < 0,1 =$ **underfitting**, $C = 1-10 =$ **zone optimale**, $C > 100 =$ **overfitting** (gap train-val s'élargit).
20. Intervalle de confiance **étroit** $\rightarrow$ modèle **stable et robuste** (performances reproductibles, estimation fiable).

Partie 4 — SVM Appliqué sur BankChurners

Q 4.1 Premier SVM sur BankChurners — pipeline complet

```
=== SVM RBF - BankChurners (C=1, gamma=scale) ===
              precision    recall  f1-score   support

Existing (0)      0.93      0.98      0.95      1701
Attrited (1)      0.87      0.60      0.71       325

   accuracy              0.92      2026
  macro avg      0.90      0.79      0.83      2026
 weighted avg      0.92      0.92      0.91      2026

AUC-ROC : 0.9466
Temps entraînement SVM : 5.53s
```

21. SVM (AUC=**0,947**) > Logistique (0,91) > Arbre (0,88) → SVM meilleur discriminateur.
22. SVM = **5,5s** vs Logistique < 0,1s → SVM trop lent pour production si mises à jour fréquentes.
23. Alternatives : **LinearSVC** (rapide, linéaire) ou **SGDClassifier(loss='hinge')** (scalable). Logistique reste le meilleur compromis performance/vitesse.

Q 4.2 GridSearch C et gamma sur BankChurners

```
Fitting 3 folds for each of 9 candidates, totalling 27 fits
Meilleurs paramètres : {'svc_C': 10, 'svc_gamma': 'scale'}
Meilleur F1 CV : 0.7433

=== SVM OPTIMAL - Évaluation finale ===
              precision    recall  f1-score   support

Existing (0)      0.95      0.97      0.96      1701
Attrited (1)      0.81      0.72      0.76       325

   accuracy              0.93      2026
  macro avg      0.88      0.84      0.86      2026
 weighted avg      0.93      0.93      0.93      2026

AUC-ROC : 0.9537
```

Q 4.3 Benchmark final — 4 modèles comparés

```
=== BENCHMARK FINAL - TD1 à TD6 ===
Modèle              F1 CV (5)      ±      F1 Test      AUC
-----
Régression Logistique      0.6325 ±0.0264      0.6077      0.9042
Arbre de Décision          0.8232 ±0.0109      0.8209      0.9364
KNN (K=7)                  0.6127 ±0.0161      0.5981      0.8931
SVM RBF (optimal)          0.7583 ±0.0092      0.7622      0.9537
```

24. **Arbre de Décision** (F1=0,821) meilleur devant SVM (0,762) et Logistique (0,608). Surprenant mais l'arbre capture bien les interactions non-linéaires.
25. SVM bon mais **pas compétitif** : F1 < arbre, AUC ≤ arbre, temps lent (5,5s), **boîte noire** → difficile à justifier vs arbre interprétable.
26. Logistique **distancée** (F1=0,608 vs 0,821). Principe d'Occam ne s'applique pas car la performance n'est pas comparable. L'arbre offre meilleur compromis performance/explicabilité.

Section Bonus — Pour aller plus loin

Bonus B1 — SVR : Régression par SVM

```
=== BONUS B1 - SVR ===  
SVR R² : 0.6372  
SVR RMSE : 0.6895  
LR R² : 0.4983  
LR RMSE : 0.8108
```

27. SVR ($R^2=0,637$) > Régression Linéaire (0,498), gain de **+0,139**. Justifié si performance prime, mais SVR plus lent → à réserver aux datasets de taille modérée.
28. Epsilon **0,01** → fit serré (risque overfitting), **0,1** → bon compromis, **0,5** → sous-apprentissage. Epsilon optimal = **0,1** (équilibre performance/généralisation).

Bonus B2 — Classification Multi-classe : OvO vs OvR

```
=== BONUS B2 - Classification Multi-classe ===  
  
=== MULTI-CLASSES SVM - IRIS (3 classes) ===  
Stratégie          Accuracy    N classifieurs  
-----  
SVC (OvO auto)      0.9737      N/A  
OvO explicite        0.9474      3  
OvR explicite        0.9737      3
```