

Partie 1 — Calcul Manuel avec le Théorème de Bayes

Q 1.1 Reprise de l'exemple météo — calcul from scratch

```
=== TABLE DE VRAISEMBLANCE ===

-- Ciel --
P(Ciel=Ensoleillé | Jouer=Oui) = 2/9 = 0.2222
P(Ciel=Ensoleillé | Jouer=Non) = 3/5 = 0.6000
P(Ciel=Nuageux | Jouer=Oui) = 3/9 = 0.3333
P(Ciel=Nuageux | Jouer=Non) = 1/5 = 0.2000
P(Ciel=Pluie | Jouer=Oui) = 4/9 = 0.4444
P(Ciel=Pluie | Jouer=Non) = 1/5 = 0.2000

-- Temperature --
P(Temperature=Chaud | Jouer=Oui) = 2/9 = 0.2222
P(Temperature=Chaud | Jouer=Non) = 2/5 = 0.4000
P(Temperature=Doux | Jouer=Oui) = 5/9 = 0.5556
P(Temperature=Doux | Jouer=Non) = 1/5 = 0.2000
P(Temperature=Frais | Jouer=Oui) = 2/9 = 0.2222
P(Temperature=Frais | Jouer=Non) = 2/5 = 0.4000

-- Humidite --
P(Humidite=Élevée | Jouer=Oui) = 4/9 = 0.4444
P(Humidite=Élevée | Jouer=Non) = 3/5 = 0.6000
P(Humidite=Normale | Jouer=Oui) = 5/9 = 0.5556
P(Humidite=Normale | Jouer=Non) = 2/5 = 0.4000

-- Vent --
P(Vent=Non | Jouer=Oui) = 6/9 = 0.6667
P(Vent=Non | Jouer=Non) = 2/5 = 0.4000
P(Vent=Oui | Jouer=Oui) = 3/9 = 0.3333
P(Vent=Oui | Jouer=Non) = 3/5 = 0.6000
```

1. $P(\text{Oui} \mid \text{Ensoleillé, Frais, Normale, Oui}) = 0,6429 \times 0,2222 \times 0,2222 \times 0,5556 \times 0,3333 = 0,0059$ (log = -5,1364)
2. $P(\text{Non}) = 0,0206$ (log = -3,8839) → **classe Non prédite** (score plus élevé).
3. Problème de **probabilité nulle** dans $P(\text{Vent=Oui} \mid \text{Non})$ ou $P(\text{Nuageux} \mid \text{Non})$ selon le dataset → le produit devient 0 → **score = $-\infty$** . Sans lissage, la prédiction échoue.

Q 1.2 Lissage de Laplace — résoudre le problème des probabilités nulles

```
=== CAS PROBLÉMATIQUE: Nuageux, Chaud, Élevée, Oui ===
SANS LISSAGE: Oui=-4.9541, Non=-4.5770 → Non
α=0.1: Oui=-4.9245, Non=-4.5623 → Non
α=1: Oui=-4.7268, Non=-4.5160 → Non
α=5: Oui=-4.3848, Non=-4.5406 → Oui
```

4. **Non** - pas de $-\infty$ ici car toutes les combinaisons existent. Mais si une combinaison manquait → **log = $-\infty$** .
5. Prédiction **reste Non** ($\alpha=1$ ne change pas l'argmax). Le lissage réduit les probabilités non-nulles en redistribuant la masse vers les valeurs non observées.
6. α très grand → probabilités **uniformisées** vers $1/|V|$. Prédiction tend vers la classe **majoritaire a priori** (ici **Oui**, car 64%), d'où le basculement à $\alpha=5$. Sous-apprentissage maximal.

Partie 2 — Les Trois Variantes Sklearn


Q 2.1 GaussianNB sur BankChurners — features continues

```
=== 2.1 GaussianNB sur BankChurners ===
              precision    recall  f1-score   support

Existing (0)       0.91       0.95       0.93       1701
Attrited (1)       0.67       0.53       0.59        325

   accuracy              0.88       2026
  macro avg       0.79       0.74       0.76       2026
 weighted avg       0.87       0.88       0.88       2026

AUC-ROC: 0.8400
```



7. Total_Trans_Ct (écart 23,94) → cohérent avec EDA (feature la plus discriminante).
8. Non → distributions asymétriques (Total_Trans_Amt, Credit_Limit) ne sont pas gaussiennes → approximation grossière.
9. GaussianNB (AUC=0,84) < Logistique (0,91) < SVM (0,95). L'hypothèse gaussienne est **trop restrictive** pour ce dataset → performances limitées.

Q 2.2 BernoulliNB — features binaires

```
=== 2.2 BernoulliNB sur Features Binaires ===
              precision    recall  f1-score   support

Existing (0)       0.87       0.97       0.92       1701
Attrited (1)       0.59       0.26       0.36        325

   accuracy              0.85       2026
  macro avg       0.73       0.61       0.64       2026
 weighted avg       0.83       0.85       0.83       2026
```

```
Top discriminantes (diff Attrited-Existing):
              Existing  Attrited  Diff
Contacts_Count_12_mon_above_median  0.459  0.684  0.225
Months_Inactive_12_mon_above_median  0.419  0.630  0.211
card_Gold  0.011  0.015  0.003
Avg_Open_To_Buy_above_median  0.499  0.501  0.002
card_Platinum  0.002  0.004  0.002
card_Silver  0.054  0.048 -0.006
Credit_Limit_above_median  0.505  0.465 -0.040
Gender  0.482  0.425 -0.057
```

10. BernoulliNB (F1=0,36) **bien inférieur** à GaussianNB (0,59). La binarisation **perd l'intensité** (50≠100 transactions devient 1) et la relation continue avec le churn.
11. Contacts_Count_12_mon_above_median (diff=0,225) → les clients qui contactent plus le service client sont plus à risque de churn.

12. $\alpha=10 \rightarrow$ probabilités **convergent vers 0,5** (uniformisation). Le modèle perd son pouvoir discriminant $\rightarrow$ ne prédit que la classe majoritaire.

Q 2.3 MultinomialNB — détection de spam SMS

```
=== 2.3 MultinomialNB - Détection de Spam SMS ===
Utilisation du mini-dataset de démonstration
label
ham      8
spam     7
Name: count, dtype: int64

=== CLASSIFICATION SPAM SMS ===

--- BoW+MNB ---
      precision    recall  f1-score   support

   Ham         1.00      1.00      1.00         2
   Spam         1.00      1.00      1.00         1

 accuracy          1.00         3
 macro avg         1.00      1.00      1.00         3
weighted avg         1.00      1.00      1.00         3

--- TF-IDF+MNB ---
      precision    recall  f1-score   support

   Ham         1.00      1.00      1.00         2
   Spam         1.00      1.00      1.00         1

 accuracy          1.00         3
 macro avg         1.00      1.00      1.00         3
weighted avg         1.00      1.00      1.00         3

Top 15 mots les plus spam: ['reply' 'luxury' 'car' 'cash' 'congratulations' 'limited' 'urgent' 'time'
'winner' 'reward' 'claim' 'click' 'prize' 'won']
```

13. Mots spam : free, cash, claim, win, urgent, prize, reply, congratulations $\rightarrow$ correspond aux intuitions (urgence, gratuité, action).
14. TF-IDF atténue les mots trop fréquents ("to", "you") et valorise les mots spécifiques aux spams $\rightarrow$ performance souvent meilleure que BoW.
15. MultinomialNB exige des **comptages non-négatifs** $\rightarrow$ BankChurners a des variables continues (et négatives après scaling). Inadapté sans transformation préalable (MinMaxScaler, seuillage). GaussianNB est préférable.

Partie 3 — Analyse de l'Hypothèse d'Indépendance

Q 3.1 Mesurer la violation d'indépendance — matrice de corrélation

16. 4 paires $|r| > 0,5$:

- Credit_Limit / Avg_Open_To_Buy (0,996)
- Total_Trans_Amt / Total_Trans_Ct (0,807)
- Customer_Age / Months_on_book (0,789)
- Gender / Income_Category (0,784)

Violation de l'hypothèse : Oui, l'hypothèse d'indépendance conditionnelle est **violée** par ces fortes corrélations.


17. $F1$ (toutes) = 0,5921 vs $F1$ (top 8) = 0,5990 → **légère amélioration** (+0,007).

Interprétation : Enlever les features redondantes ne dégrade pas les performances (elles sont légèrement meilleures). La redondance **n'apporte pas d'information supplémentaire** et peut même **détériorer** le modèle car NB compte la même information deux fois. Sélectionner les features les plus informatives (MI) permet de **réduire la redondance** et d'améliorer l'efficacité.

18. Credit_Limit et Avg_Open_To_Buy corrélées à 0,99 → inclure les deux revient à **compter deux fois la même information**. Le **lissage de Laplace ne résout pas ce problème** car :

- Le lissage n'est qu'un **ajustement des probabilités** (évite les zéros)
- Il ne **décorrèle** pas les features
- La double information reste présente dans le produit des vraisemblances → **biais de surestimation** de la probabilité

Q 3.2 Calibration des probabilités — NB vs Régression Logistique



19. GaussianNB est **over-confident** (s'écarte de la diagonale) → probabilités trop extrêmes (proches de 0 ou 1).
20. Régression Logistique (Brier=0,079) < GaussianNB (0,091) → **Régression Logistique mieux calibrée**.
21. **Régression Logistique** — ses probabilités sont plus **fiables** (Brier plus bas). Pour optimiser le budget rétention, on veut une estimation précise du risque, pas des probabilités extrêmes biaisées.

Partie 4 — Benchmark Complet et Positionnement


Q 4.1 Benchmark 5 modèles — TD 4 à 7

Modèle	F1 CV	±	F1 Test	AUC	Temps (s)
Naive Bayes (Gaussian)	0.6568	±0.0230	0.5921	0.8400	2.64
Régression Logistique	0.6325	±0.0264	0.6077	0.9042	0.23
Arbre de Décision	0.8232	±0.0109	0.8209	0.9364	0.44
KNN (K=7)	0.6127	±0.0161	0.5981	0.8931	0.41
SVM RBF	0.7318	±0.0220	0.7067	0.9466	56.29

22. NB = **2,64s** (plus lent que Logistique 0,23s), mais **plus rapide que SVM** (56s).
23. NB **pas compétitif** : F1 (0,592) < Arbre (0,821), AUC (0,840) < SVM (0,947). Prix : médiocre en performance et calibration.
24. Recommander NB pour : **texte** (spam), **très grande dimension** (scalable), **streaming** (partial_fit), **baseline rapide**, **peu de données**. Éviter quand calibration critique ou performance absolue requise.

Section Bonus — Pour aller plus loin

Bonus B1 — Apprentissage en ligne avec `partial_fit()`



25. Le F1 **converge vers 0,592** (batch complet) après **8-10 batches** (4000-5000 exemples).
L'apprentissage online atteint les mêmes performances.
26. `partial_fit()` supporté par
: **BernoulliNB**, **MultinomialNB**, **SGDClassifier**, **Perceptron**, **PassiveAggressiveClassifier**. Utile
pour données en streaming ou trop volumineuses pour la mémoire.

Bonus B2 — Calibration de Naive Bayes avec `CalibratedClassifierCV`

